WIRTSCHAFTLICHKEIT · OPEN-WEIGHT-KI SELBST GEHOSTET · 12 MONATE

Rechnet sich die eigene KI (bei sich im Haus) für 50 Entwickler?

8,8 Mio. € gespart · 5× Produktivität nach 12 Monaten

50 Entwickler, ein 8× NVIDIA H100 Node, ein Open-Weight-Modell. Was kostet das, wie viele User Stories bringt es zusätzlich – und wie viel spart das Unternehmen in einem Jahr?

STRATEGIE

Die Ziele: souverän, unabhängig, DSGVO-konform – und produktiver

01 Digitale Souveränität
Modelle, Gewichte und Daten laufen auf eigener bzw. europäisch betriebener Hardware – ohne Zugriff über den US CLOUD Act.

02 Kein US-Vendor-Lock-in
Open-Weight-Modelle sind austauschbar. Keine Bindung an Preise, Nutzungsbedingungen oder Verfügbarkeit einer US-API.

03 DSGVO-Konformität
Quellcode und personenbezogene Daten verlassen den eigenen Verantwortungsbereich nicht. Kein Drittlandtransfer.

04 Produktivität zu planbaren Kosten
Mehr Leistung des Teams ohne Neueinstellungen – zum festen Monatspreis statt Abrechnung pro Token.

Die Rechnung unten prüft, ob diese Strategie auch wirtschaftlich trägt.

1 · Kosten pro Monat

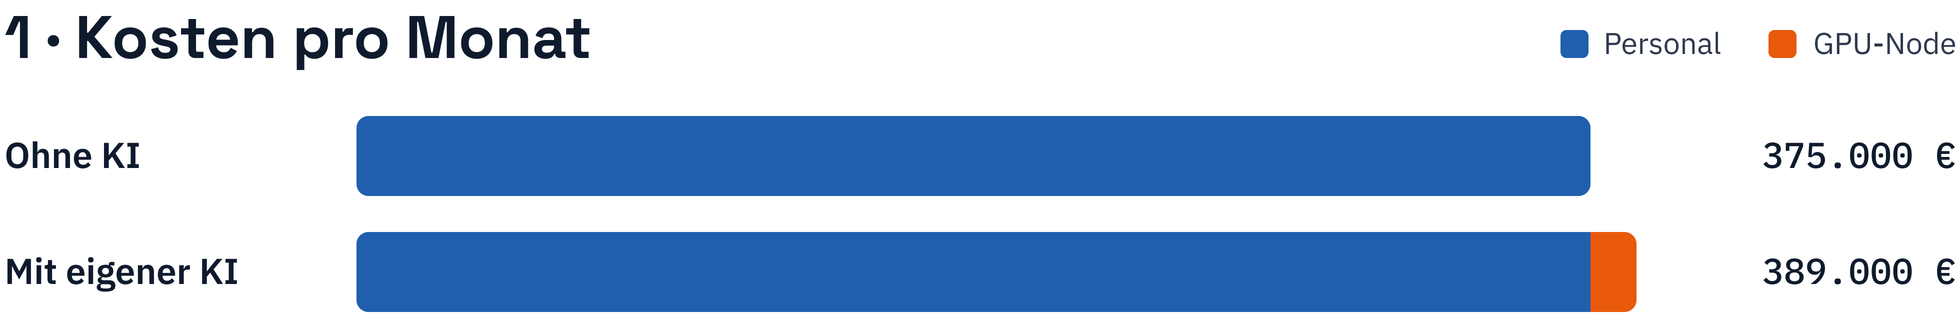

Der GPU-Node mit ca. **14.000 €** macht nur **+3,7 %** der Teamkosten aus – der schmale orange Streifen.

2 · Break-Even pro Entwickler

18 min

So viel Zeit muss jeder Entwickler am Tag durch KI einsparen, damit der GPU-Node sein Geld wieder einbringt.

Der Node kostet 3,7 % der Personalkosten – und 3,7 % eines 8-Stunden-Tages sind 18 Minuten. Für das ganze Team heißt das: nur 15 User Stories mehr pro Monat. Jede weitere Minute ist Gewinn.

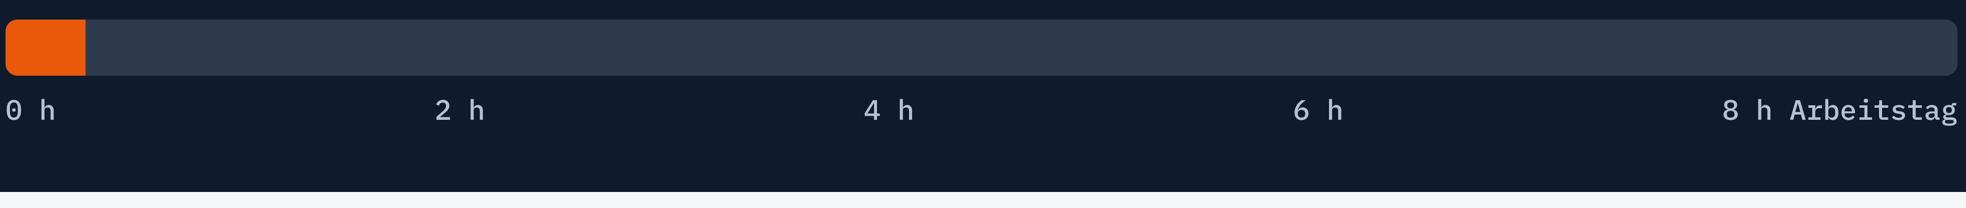

3 · Produktivität: 5× nach 12 Monaten – 2.000 statt 400 User Stories pro Monat

Ohne KI bleibt der Durchsatz bei 400 Stories. Mit KI steigt die Produktivität gleichmäßig von 1× auf 5,0× – und der Durchsatz auf 2.000 Stories im zwölften Monat.

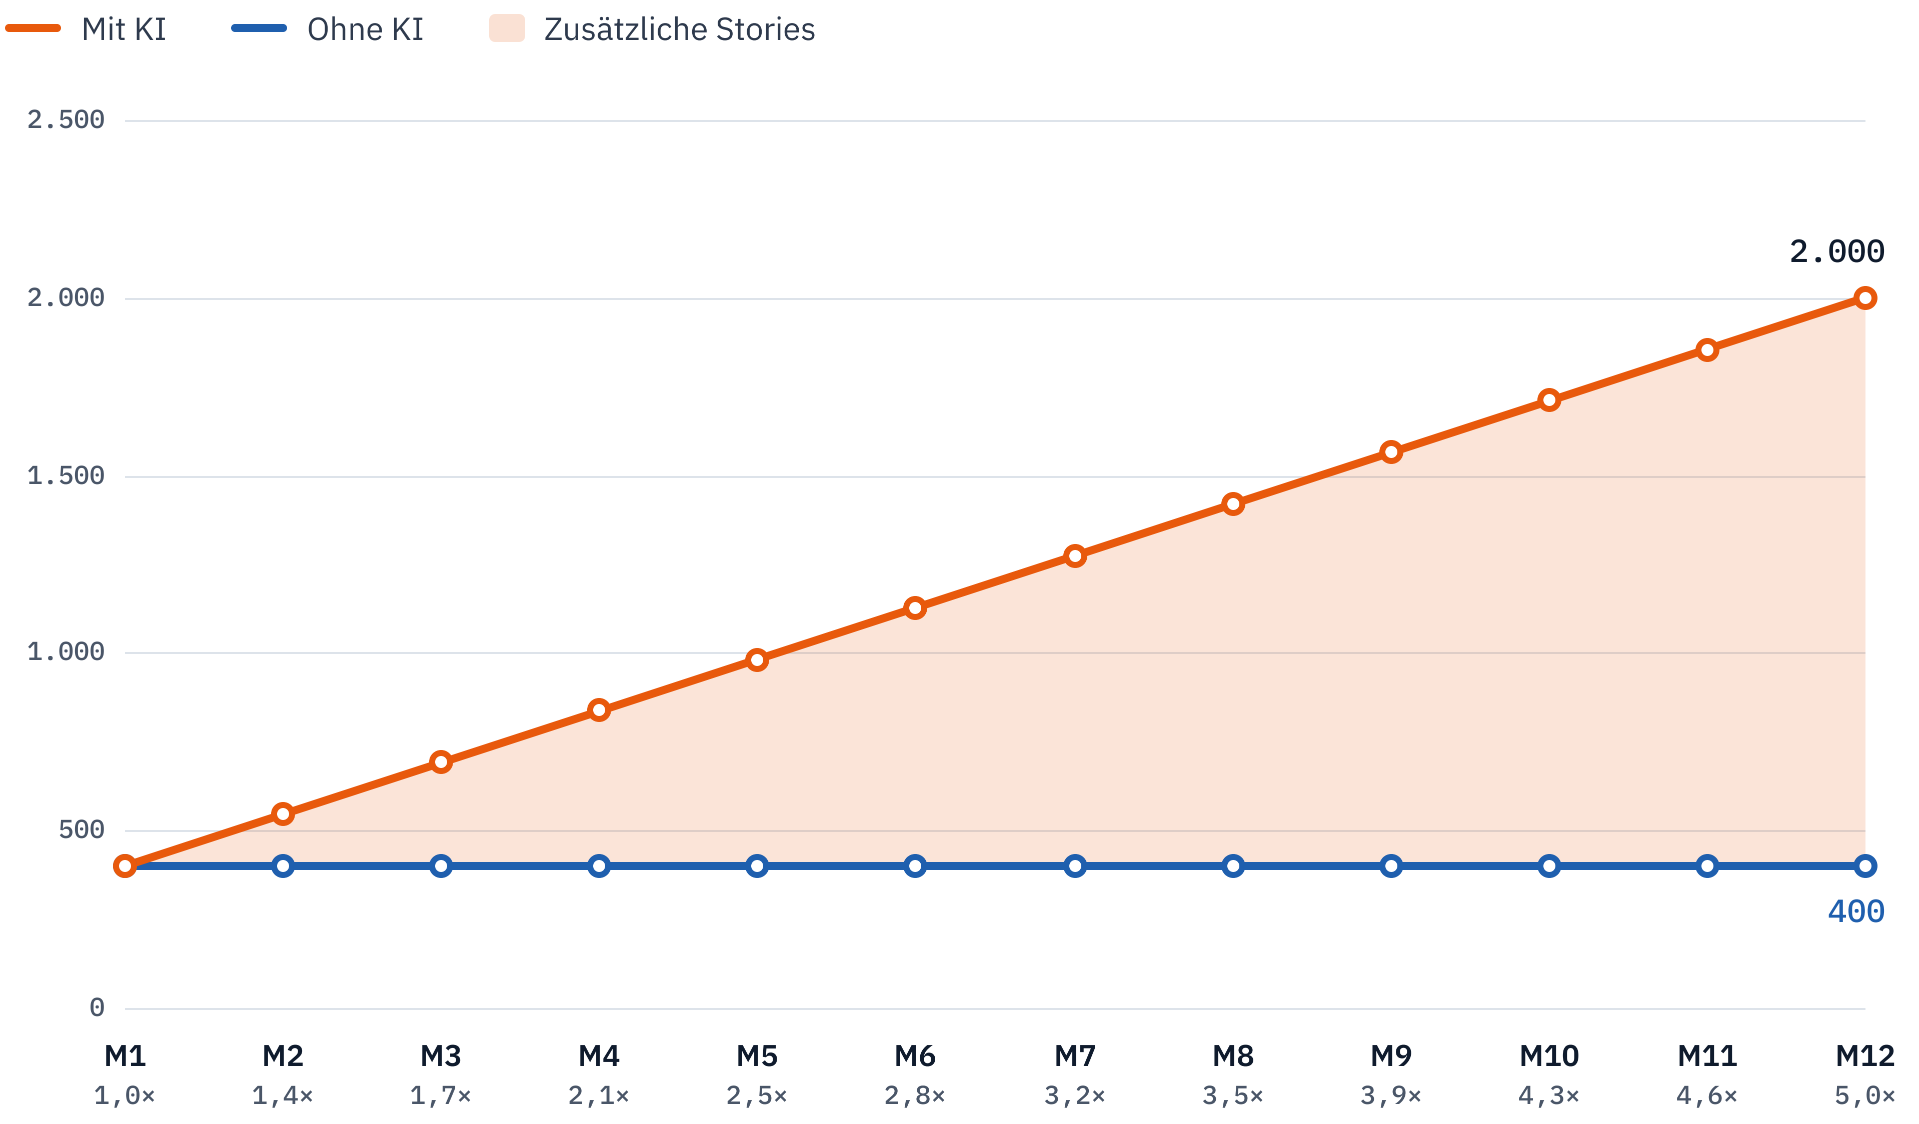

Achse: User Stories des ganzen Teams pro Monat · unter dem Monat: Produktivitätsfaktor

4 · Kostenersparnis: 8,8 Mio. € in 12 Monaten

Was würde dieselbe Leistung ohne KI kosten? Man bräuchte entsprechend mehr Entwickler. Die Differenz zu den tatsächlichen Kosten ist die Ersparnis.

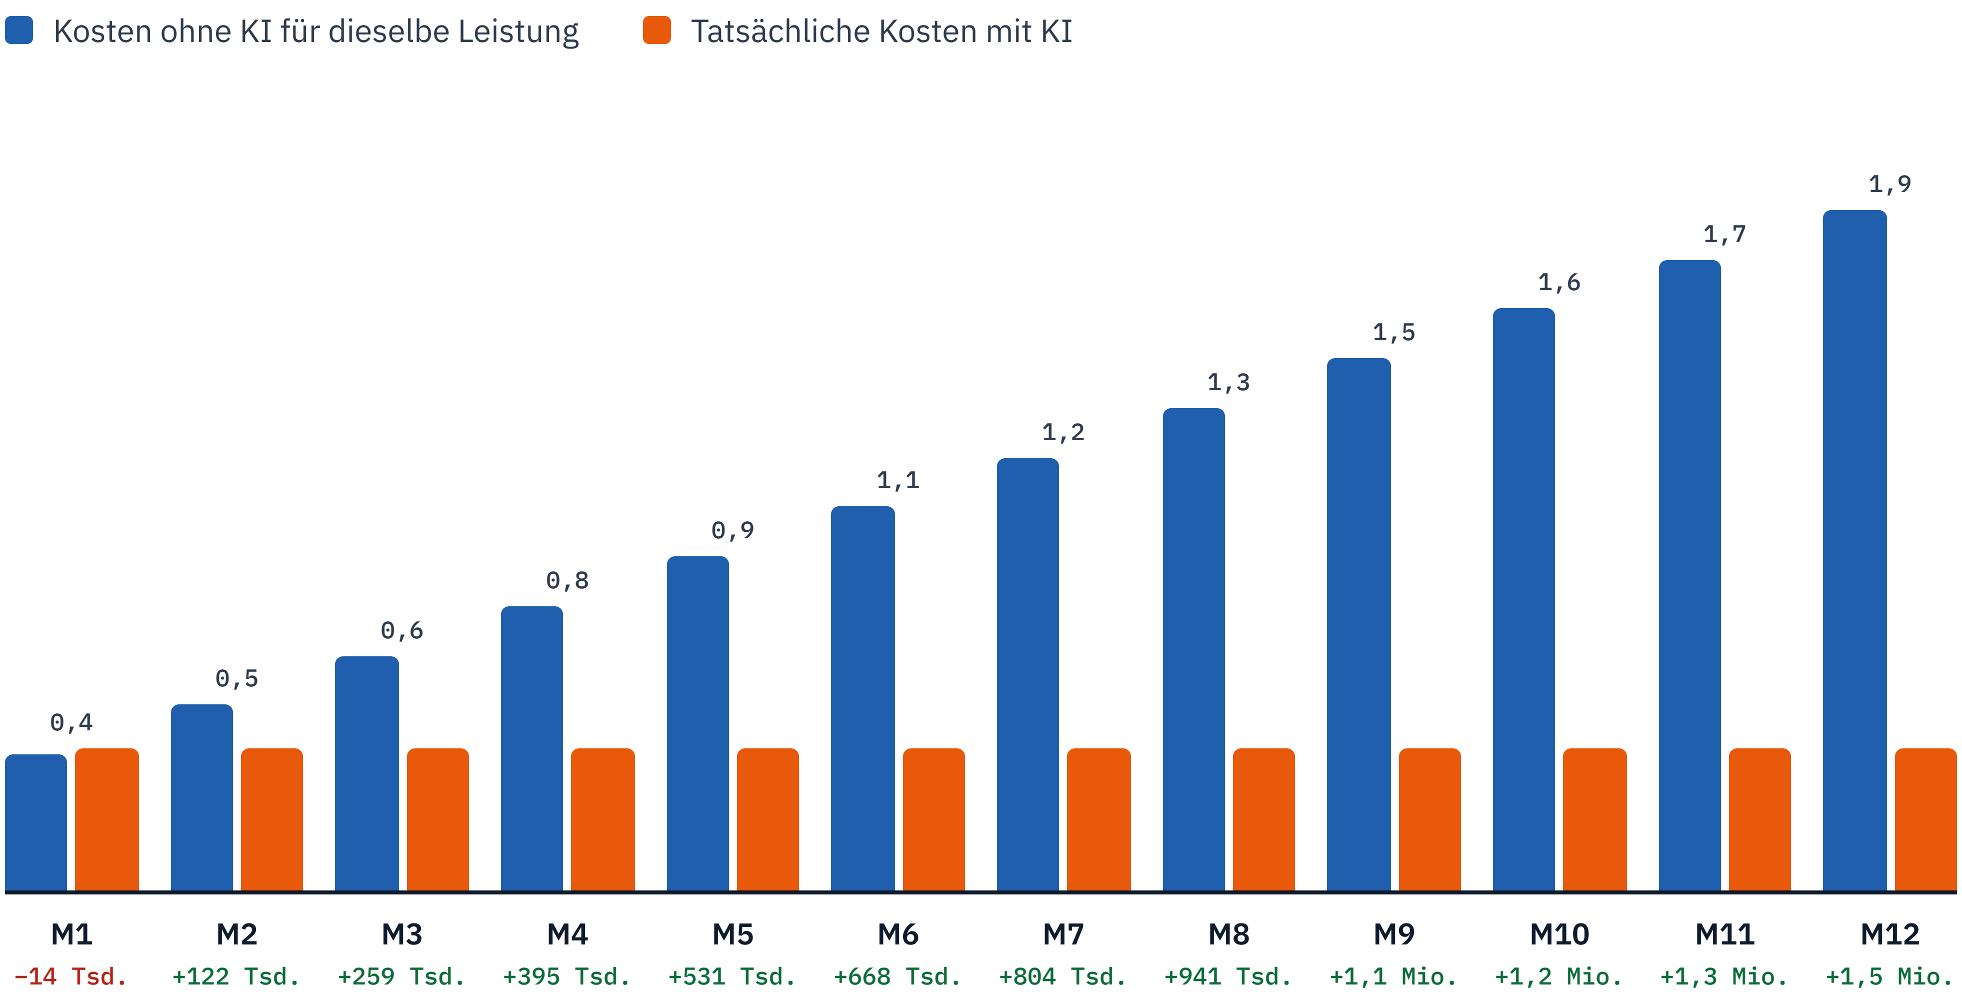

Über den Säulen: Kosten ohne KI in Mio. € · unter dem Monat: Ersparnis

5 · Jahresbilanz: 8,8 Mio. € netto

Mehrwert durch KI	+ 9,0 Mio. €
GPU-Kosten	– 168.000 €
Ersparnis netto	**+ 8,8 Mio. €**
Amortisiert in	Monat 2
User Stories im Jahr	4.800 → 14.400
Kosten je Story	938 € → Ø 324 €

Dieselbe Leistung kostet mit KI 65 % weniger. Mit 4 Nodes für intensive Agenten-Nutzung bleiben netto 8,3 Mio. €.

6 · Preis der Souveränität

8× H100 bei	€/Jahr	vom Nutzen
Gcore Bare Metal	159.120	1,8 %
Annahme	168.000	1,9 %
STACKIT (DE)	555.800	6,2 %

Selbst voll souverän in Deutschland bleibt die Hardware ein kleiner Bruchteil des Nutzens.

Annahmen: 7.500 € Arbeitgeberkosten je Entwickler und Monat · 8-h-Tag · 8 User Stories je Entwickler und Monat ohne KI (ca. 2,5 Personentage je Story) · Produktivität steigt linear von 1× auf 5,0× – ein optimistisches Szenario; kontrollierte Studien messen bisher meist kleinere Effekte · Mehrwert = zusätzliche Leistung × Personalkosten · Recruiting, Einarbeitung und interner Betriebsaufwand nicht enthalten · Mehr Durchsatz setzt voraus, dass Stories schnell genug geschrieben, abgenommen und ausgeliefert werden.

Quellen: gcore.com/de/pricing/ai (8×H100 SXM Bare Metal, 18,16 €/h × 730 h) · stackit.de Preisliste Compute Engine GPU (n3.104d.g8). Alle Preise netto, Stand Oktober 2026.